

*Міністерство освіти і науки України НТУУ
«Київський політехнічний інститут імені Ігоря Сікорського»
Фізико-технічний інститут*

ПРОТОКОЛ
до лабораторної роботи №1
З дисципліни **«Методи машинного навчання»**
«Лінійна регресія»

Виконав:
студент 4 курсу ФТІ
групи ФІ-31
Горбач Ангеліна

Тема роботи

Прогнозування ціни вживаних автомобілів методами регресії.

Мета роботи

Підготувати реальний набір даних для задачі регресії, самостійно реалізувати лінійні моделі, оцінити їхню точність і порівняти з готовими реалізаціями та XGBoost.

Завдання

На відкритому наборі даних про продаж автомобілів проаналізувати ознаки, очистити пропуски й аномалії, поділити записи на навчальні та тестові у співвідношенні 70:30. Побудувати власні OLS, Ridge і Lasso, підібрати параметри регуляризації без використання тестової вибірки та порівняти результати зі sklearn. Додатково оцінити XGBoost як нелінійну модель.

Хід роботи

1. Дані та очищення

Для роботи використано публічний набір Vehicle Dataset from CarDekho: 8128 оголошень і 13 початкових стовпців. Цільова змінна — `selling_price`, тобто ціна продажу. Для прогнозу взято вік авто, пробіг, марку, пальне, тип продавця, коробку передач, кількість власників та технічні характеристики.

Спочатку видалено 1202 повні дублікати. Із назви авто виділено марку, рік випуску перетворено на вік, із текстових значень витягнуто числа. Крутий момент, записаний у `kgm`, переведено у `Nm`; нульову витрату пального й потужність позначено як пропуски. Окремо видалено 2 записи з пробігом понад 1 000 000 км. Після цього залишилося 6924 рядки.

Частину значень технічних характеристик не заповнювали до поділу даних. Медіани й найчастіші категорії обчислювали тільки на навчальній вибірці, щоб інформація з тесту не впливала на навчання.

2. Аналіз ознак




Рисунок 1 – Розподіл ціни до та після логарифмування

Початкові ціни мають довгий правий хвіст: кілька дорогих автомобілів сильно відрізняються від решти. Асиметрія становить 5,57. Після переходу до $\log(\text{ціна} + 1)$ вона стає $-0,16$. Тому моделі прогнозують логарифм ціни, а помилки оцінюються вже після повернення до початкових одиниць.




Рисунок 2 – Кореляції числових ознак

Найсильніший додатний зв'язок із ціною має потужність двигуна (0,69). Для об'єму двигуна та крутного моменту кореляція близько 0,44, для віку автомобіля — $-0,43$. Деякі технічні ознаки пов'язані також між собою, тому поряд зі звичайною лінійною регресією перевірено Ridge і Lasso.

3. Поділ даних і побудова моделей

Із 6924 підготовлених рядків 4846 взято для навчання, 2078 — для тестування. Числові пропуски заповнено медіанами, категорійні — найчастішими значеннями; числові ознаки масштабовано, категорійні закодовано. Після кодування отримано 45 ознак. Частина навчальної вибірки тимчасово виділено для підбору параметрів; тест у цьому підборі не використовувався.

Самостійно реалізовано три моделі: OLS через псевдообернену матрицю, Ridge зі штрафом за великі коефіцієнти й Lasso з координатним спуском. Для Ridge найменшу помилку валідації дало $\alpha = 0,2$, для Lasso — $\alpha = 0,00007$. Після вибору α моделі повторно навчено на всіх 4846 навчальних рядках.

4. Результати на навчальній і тестовій вибірках

У таблиці 1 наведено помилки власних моделей у початкових одиницях ціни. MAE показує середнє абсолютне відхилення прогнозу, а R^2 — частку мінливості ціни, яку пояснює модель.

Модель	Train MAE	Test MAE	Train R ²	Test R ²
Власна OLS	93 998	94 039	0,8835	0,8795
Власна Ridge	94 080	94 756	0,8827	0,8751
Власна Lasso	94 347	95 645	0,8817	0,8691

Найкращий результат серед власних моделей дала OLS: RMSE на навчанні — 173 534, на тесті — 189 377. Тестова MAE становить 94 039, $R^2 = 0,8795$. Ridge і Lasso на цьому поділі трохи поступилися OLS за тестовою помилкою. Lasso залишила 42 ненульові коефіцієнти з 45.

5. Порівняння з готовими моделями

Готові OLS, Ridge і Lasso зі sklearn навчено на тих самих даних і з тими самими параметрами. У таблиці 2 порівняно їхню тестову MAE з власними реалізаціями.

Метод	Власна MAE	sklearn MAE	Найбільша різниця прогнозів
OLS	94 039	94 039	0,00
Ridge	94 756	94 756	0,00
Lasso	95 645	95 645	2,31

Для OLS і Ridge прогнози збіглися з готовими реалізаціями в межах показаної точності. Для Lasso найбільша різниця прогнозу — 2,31 одиниці ціни; на тлі MAE понад 95 тисяч це дуже мало. Отже, власні алгоритми відтворюють результат бібліотечних моделей.

XGBoost перевірено окремо як нелінійний орієнтир. Після вибору параметрів на валідаційній вибірці він отримав Test MAE = 71 009, Test RMSE = 144 765 і Test $R^2 = 0,9296$. Це кращий тестовий результат, ніж у лінійних моделей, але XGBoost у цій роботі використано як готову реалізацію для додаткового порівняння.




Рисунок 3 – Справжня й прогнозована ціна та залишки власної OLS

Більшість прогнозів близька до червоної діагоналі, особливо для недорогих автомобілів. Для окремих дорогих авто відхилення значно більші. На графіку залишків це видно як поодинокі точки далеко від нуля.

Контрольні питання

1. Що таке ансамблювання? Це поєднання прогнозів кількох моделей. Воно може зменшити вплив помилок окремої моделі, якщо ці помилки відрізняються.
2. Які моделі базуються на лінійній перспективі? У цій роботі це OLS, Ridge і Lasso. Вони будують прогноз як лінійну комбінацію ознак, але Ridge і Lasso додатково обмежують коефіцієнти.
3. Що таке XGBoost? Це градієнтний бустинг над деревами: кожне наступне дерево уточнює прогноз попередніх. Метод може враховувати нелінійні залежності.

Висновок

Дані про вживані автомобілі очищено, досліджено та поділено 70:30. Власні OLS, Ridge і Lasso дали результати, близькі до відповідних моделей sklearn. Серед власних моделей найменшу тестову помилку мала OLS: $RMSE = 189\,377$, $R^2 = 0,8795$. XGBoost показав нижчу помилку, що вказує на залежності ціни, які лінійні моделі не повністю враховують.